

Premier League

Un modèle de simulation d'évènements rares

Raphaël Montaud et Gabriel Misrachi

Modal Simulation d'évènements rares MAP474D - Ecole Polytechnique

Table of contents

1. Introduction
2. Le modèle de Bradley-Terry (1952)
3. Premières implémentations
4. Evènements rares
5. Comportement sur de grands championnats
6. Recherche de paramètres optimaux
7. Conclusion

Introduction

- les championnats de football: un monde incertain

- les championnats de football: un monde incertain
- Premier League 2015-2016:

- les championnats de football: un monde incertain
- Premier League 2015-2016:
 - Leicester gagne

- les championnats de football: un monde incertain
- Premier League 2015-2016:
 - Leicester gagne
 - Manchester City et Manchester United hors podium

- les championnats de football: un monde incertain
- Premier League 2015-2016:
 - Leicester gagne
 - Manchester City et Manchester United hors podium
 - Liverpool et Chelsea hors places européennes

- les championnats de football: un monde incertain
- Premier League 2015-2016:
 - Leicester gagne
 - Manchester City et Manchester United hors podium
 - Liverpool et Chelsea hors places européennes
- une côte à un 1 contre 5000: 30 millions de pertes pour les bookmakers

Le modèle de Bradley-Terry (1952)

Le modèle de Bradley-Terry (1952)

Un vecteur de force ou de mérite V . On a ensuite chaque rencontre qui est le résultat d'une expérience de Bernoulli:

$$P(X_{i,j} = 1) = \frac{V_i}{V_i + V_j}$$

Premières implémentations

- un modèle pour le calcul des forces: $(\text{score année précédente})^\kappa$

- un modèle pour le calcul des forces: (score année précédente) ^{κ}
- matrice des résultats:

$$\begin{pmatrix} N & 0 & 0 & 1 \\ 1 & N & 1 & 0 \\ 1 & 0 & N & 0 \\ 0 & 1 & 1 & N \end{pmatrix}$$

- un modèle pour le calcul des forces: $(\text{score année précédente})^\kappa$
- matrice des résultats:

$$\begin{pmatrix} N & 0 & 0 & 1 \\ 1 & N & 1 & 0 \\ 1 & 0 & N & 0 \\ 0 & 1 & 1 & N \end{pmatrix}$$

- premier résultat:

Premières implémentations

```
according to our model, we compute the chances of winning for the best teams
(given with a 95% interval)
proba of winning for Chelsea with n = 80000: 37.0625% +- 0.334872092679%
proba of winning for ManCity with n = 80000: 25.5375% +- 0.301060990353%
proba of winning for Arsenal with n = 80000: 20.4425% +- 0.279516471263%
proba of winning for ManU with n = 80000: 15.007499999999999% +- 0.24668839648%
proba of winning for Tottenham with n = 80000: 9.3125% +- 0.202190825793%
We now compare it to the probabilities according to the bookmakers
Chelsea: 38.095238095238095%
ManCity: 28.57142857142857%
Arsenal: 22.22222222222222%
ManU: 16.666666666666664%
Tottenham: 0.9900990099009901%
```


Evènements rares

- Les limites de la simulation de Monte-Carlo standard
- La méthode de décalage en probabilité
- Théorème ergodique et splitting

Décalage en probabilité: un résultat utile

Y_1, \dots, Y_k Bernoulli indépendantes $B(p_1), \dots, B(p_k)$; et Z_1, \dots, Z_k Bernoulli indépendantes $B(q_1), \dots, B(q_k)$. Pour toute fonction mesurable bornée g , on a :

$$\mathbb{E}[g(Y_1, \dots, Y_k)] = \left(\prod_{i=1}^k \frac{1-p_i}{1-q_i} \right) \mathbb{E} \left[g(Z_1, \dots, Z_k) \prod_{i=1}^k \left(\frac{p_i(1-p_i)}{q_i(1-q_i)} \right)^{Z_i} \right]$$

On l'utilise en remplaçant g par l'indicatrice de l'événement considéré.

- forcer l'événement

- forcer l'événement
- simplification des calculs

Décalage en probabilité: implémentation et résultats

- forcer l'événement
- simplification des calculs
- résultats

Événement	Probabilité	Intervalle	Simulations
Leicester gagne	0,41%	0,025%	10 000
Événement complexe	0,0069%	0,0024%	1 000 000

- On ne resimule qu'une fraction des matchs \rightarrow construction d'une chaîne de Markov avec un nombre d'états finis.

- On ne resimule qu'une fraction des matchs → construction d'une chaîne de Markov avec un nombre d'états finis.
- rejet des scores trop faibles

Théorème ergodique et splitting

- On ne resimule qu'une fraction des matchs \rightarrow construction d'une chaîne de Markov avec un nombre d'états finis.
- rejet des scores trop faibles
- comptage des scores suffisants

- On ne resimule qu'une fraction des matchs → construction d'une chaîne de Markov avec un nombre d'états finis.
- rejet des scores trop faibles
- comptage des scores suffisants
- calcul de la probabilité finale:

$$P(\text{Leicester gagne}) = P(\text{Leicester gagne} | \text{score} > 10) \dots P(\text{score} > 3)$$

- taux de rejet idéal $\simeq 20\%$

- taux de rejet idéal $\simeq 20\%$
- taux de rejet élevés (même avec $\rho = 1$ *match*)

- taux de rejet idéal $\simeq 20\%$
- taux de rejet élevés (même avec $\rho = 1$ *match*)
- $\{Leicester\ gagne | Leicester\ deuxieme\}$ est un évènement rare

- taux de rejet idéal $\simeq 20\%$
- taux de rejet élevés (même avec $\rho = 1$ match)
- $\{\text{Leicester gagne} | \text{Leicester deuxième}\}$ est un évènement rare
- → méthode peu adaptée au problème

Comportement sur de grands championnats

R. Chetrite, R. Diel, M. Lerasle *The number of potential winners in Bradley-Terry model in random environment*, Ann. Appl. Probab., 2016. [lien](#)

⇒ **trois théorème que nous allons illustrer**

Théorème 1

Théorème 1:

Q la fonction quantile, U la distribution des forces. Si:


- Il existe β dans $(0, 1/2)$ et $x_0 > 0$ dans l'intérieur de $\text{supp}Q$ tels que $Q^{1/2-\beta}$ est convexe sur $[x_0, \infty)$.
- $E[U^2] < \infty$.

Alors, la probabilité que le joueur le plus fort gagne tend vers 1 avec le nombre N de joueurs:

$$P(\text{le plus fort gagne}) \xrightarrow[N \rightarrow +\infty]{} 1.$$


Theorème 1: Résultats

Cas de la distribution de queue en x^{-b}



Theorème 1: Résultats

Cas de la distribution log-normale



Théorème 2

Hypothèse A:

Le maximum de $\text{supp}(Q)$ est 1 et il existe $\alpha \in [0, 2)$ tel que:

$$\log Q(1 - u) = \alpha \log(u) + o(\log u) \text{ quand } u \rightarrow 0 \quad (A)$$

Théorème 2:

Pour tout $\gamma < 1 - \alpha/2$, on a pour N tendant vers l'infini:

$$P(\text{aucun des } N^\gamma \text{ meilleurs joueurs gagne}) \rightarrow 1$$


Pour tout $\gamma > 1 - \alpha/2$, on a pour N tendant vers l'infini:

$$P(\text{un des } N^\gamma \text{ meilleurs joueurs gagne}) \rightarrow 1$$


Lois respectant l'hypothèse A

- la distribution uniforme avec $\alpha = 1$
- la distribution *arcsin* avec $\alpha = 1/2$
- les distributions $\beta(a, b)$ avec $\alpha = b$ si $b < 2$


Théorème 2



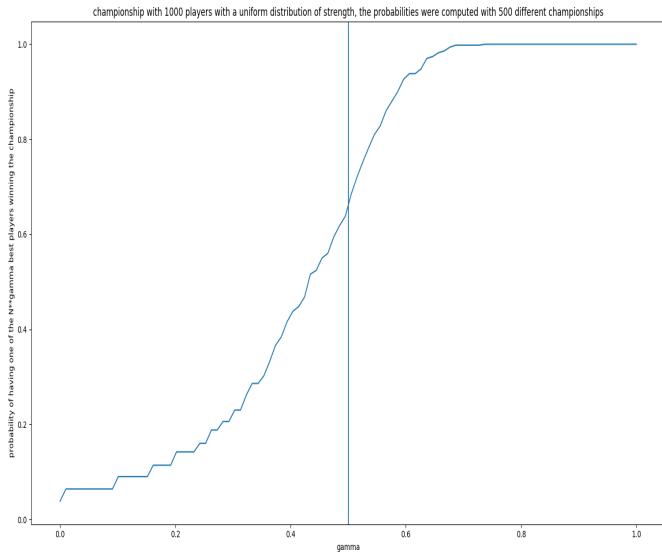
Théorème 2




Théorème 2



Théorème 2



Théorème 2



Théorème 3

Encore sous l'hypothèse A:

Théorème 3

$$\text{Soit } V_U = \mathbb{E}\left[\frac{U}{(U+1)^2}\right] \text{ et } \epsilon_N = \left(\frac{(2-\alpha)(\log N)}{NV_U}\right)^{1/2}$$

Si x_N représente la force d'un $N+1$ e joueur alors: Si


$\liminf_{N \rightarrow \infty} \frac{x_N - 1}{\epsilon_N} > 1$ alors P presque sûrement:

$$P(\text{le } N+1 \text{e joueur gagne}) \rightarrow 1$$

Si $\limsup_{N \rightarrow \infty} \frac{x_N - 1}{\epsilon_N} < 1$ alors P presque sûrement:

$$P(\text{le } N+1 \text{e joueur ne gagne pas}) \rightarrow 1$$

Théorème 3




Un cas particulier:

- Une équipe possède une force de 2 tandis que toutes les autres possèdent une force de 1
- Une équipe possède une force de 2, une autre une force de 1 et tout le reste a une force de 0.5.

⇒ On crée un script qui calcule la plus petite force nécessaire pour gagner avec 70% de chances

Théorème 3




Recherche de paramètres optimaux


Idée: les bookmakers évaluent bien les probabilités pour les grandes équipes mais pas pour les plus petites.

⇒ on va se fixer nos paramètres sur les valeurs des bookmakers.


Un premier tracé de la fonction de coût




Un deuxième tracé plus précis



Intervalle de confiance



Interpolation



- Minimum de la fonction interpolée $\kappa = 1.690$
- injection dans le modèle. Victoire de Leicester: $0.20\% \pm 0.013\%$
- côte à 5000 \rightarrow une espérance de 90 euros pour 10 euros misés
- 1000 évènements \rightarrow 14% de chances de tout perdre et $E[\text{gain}] = 90\,000$

Gradient descent ?

- Une solution généralement préférée

Gradient descent ?

- Une solution généralement préférée
- Trop de bruit

Gradient descent ?

- Une solution généralement préférée
- Trop de bruit
- Pas de reproductibilité des résultats

Gradient descent ?

- Une solution généralement préférée
- Trop de bruit
- Pas de reproductibilité des résultats
- → on rejette les résultats obtenus

Conclusion

- La nécessité des décalages en probabilité

- La nécessité des décalages en probabilité
- Une théorie intéressante, pas toujours applicable au football

- La nécessité des décalages en probabilité
- Une théorie intéressante, pas toujours applicable au football
- Une optimisation des paramètres très coûteuse en temps de calcul

- La nécessité des décalages en probabilité
- Une théorie intéressante, pas toujours applicable au football
- Une optimisation des paramètres très coûteuse en temps de calcul
- Le football un problème encore ouvert, important pour de nombreux acteurs économiques

Questions?